

LAPORAN TUGAS AUTOENCODER FASHION-MNIST

Nama: [rosyid muzaki putro]

NIM: [452044611058]

1. Analisis Peran Komponen Autoencoder dan Mekanisme Latent Space

Pemodelan arsitektur jaringan saraf tiruan berjenis *autoencoder* yang diterapkan pada dataset citra Fashion-MNIST ini secara mendasar bertumpu pada interaksi harmonis antara dua komponen utama, yaitu *encoder* dan *decoder*. Komponen *encoder* dikembangkan menggunakan lapisan linier berurutan (*Sequential Linear Layers*) berdimensi 28×28 (784 unit input), yang dipetakan menuju lapisan tersembunyi berukuran 512 unit, kemudian 128 unit, hingga bermuara pada ruang representasi berdimensi rendah yang disebut sebagai *latent space* (ruang laten). Peran utama dari *encoder* ini adalah melakukan kompresi fitur spasial berdimensi tinggi secara non-linier dengan bantuan fungsi aktivasi *Rectified Linear Unit* (ReLU) guna menyaring kebisingan citra (*noise*) serta mereduksi redundansi data. Informasi yang berhasil lolos dari penyaringan tersebut akan disimpan ke dalam *latent vector*. Sebaliknya, komponen *decoder* bekerja dengan logika terbalik, di mana ia menerima *latent vector* berdimensi sempit tersebut sebagai satu-satunya landasan informasi dasar untuk kemudian diekspansikan kembali secara bertahap (melalui lapisan linier 128, 512, hingga kembali ke dimensi asal 784 piksel). Lapisan keluaran pada *decoder* memanfaatkan fungsi aktivasi Sigmoid untuk memastikan bahwa nilai intensitas piksel citra yang direkonstruksi berada pada rentang kontinu antara 0 dan 1, sehingga mampu menghasilkan representasi visual pakaian yang serupa dengan citra masukan aslinya.

2. Proses Pelatihan di Kaggle dan Grafik Loss

Proses pelatihan model dilaksanakan menggunakan lingkungan Kaggle Notebook dengan memanfaatkan akselerator perangkat keras untuk mempercepat komputasi. Model dilatih menggunakan fungsi kerugian *Mean Squared Error* (MSE) Loss dan dioptimalkan menggunakan algoritma Adam dengan *learning rate* sebesar 0.001. Pelatihan dilakukan secara terpisah untuk tiga variasi ukuran *latent dimension* yang berbeda, yaitu dimensi 2, 8, dan 32, guna mengamati perilaku konvergensi model.

Berdasarkan grafik *training loss* yang diperoleh, ketiga model menunjukkan tren penurunan *loss* yang stabil seiring bertambahnya epoch, yang menandakan bahwa proses pembelajaran berjalan dengan baik. Namun, terdapat perbedaan performa yang signifikan pada nilai konvergensi akhir di mana model dengan dimensi laten 32 mencapai nilai *loss* terendah, diikuti oleh dimensi 8, dan nilai *loss* tertinggi berada pada dimensi 2.

3. Analisis Pengaruh Latent Dimension terhadap Kualitas Visual

Hasil eksperimen menunjukkan adanya hubungan kausalitas yang sangat erat antara ukuran *latent dimension* dengan kualitas visual citra rekonstruksi serta nilai *loss* akhir. Ketika model dipaksa menggunakan *latent dimension* yang sangat kecil, yaitu 2, terjadi fenomena penyumbatan informasi (*information bottleneck*) di mana informasi citra terpaksa dipangkas secara ekstrem. Akibatnya, sebagian besar detail penting dari pakaian hilang, nilai *loss* menetap di angka yang cukup tinggi, dan citra yang direkonstruksi terlihat sangat buram atau hanya berupa siluet kasar.

Ketika kapasitas ruang laten ditingkatkan menjadi 8 dan dioptimalkan secara maksimal pada dimensi 32, model memiliki ruang parameter yang jauh lebih kaya untuk mengodekan informasi. Hasil rekonstruksi pada dimensi 32 memperlihatkan kualitas visual yang sangat tajam, bersih, dan mampu mempertahankan detail-detail kecil seperti kerah kemeja atau bentuk tali sepatu, yang selaras dengan penurunan nilai *loss* secara drastis. Hal ini membuktikan bahwa semakin besar dimensi ruang laten, semakin banyak informasi spasial yang dapat dipertahankan oleh *encoder* untuk diserahkan kepada *decoder*.

4. Korelasi Nilai Kuantitatif Loss terhadap Kualitas Visual Citra Rekonstruksi

Berdasarkan eksperimen riil yang telah dijalankan sepanjang 15 epoch pelatihan menggunakan pengoptimal Adam dan fungsi kerugian *Mean Squared Error* (MSE), ditemukan adanya hubungan kausalitas yang sangat signifikan antara kapasitas dimensi ruang laten, penurunan nilai *loss* kuantitatif, dan ketajaman visual gambar yang dihasilkan. Pengujian dilakukan pada tiga variasi dimensi laten yang berbeda dengan catatan performa sebagai berikut:

Dimensi Laten (Latent Dimension)	Nilai Training Loss Akhir (MSE)	Karakteristik Kualitas Hasil Visual Citra
Dimensi 2	0.0247	Buram, kehilangan detail tekstur, hanya membentuk siluet kasar.
Dimensi 8	0.0124	Cukup jelas, bentuk dasar objek pakaian sudah mulai teridentifikasi.
Dimensi 32	0.0085	Sangat detail, bersih, dan mampu merekonstruksi fitur intrinsik objek.

Dari data di atas terlihat jelas bahwa ketika model dipaksa bekerja pada dimensi laten yang sangat sempit (Dimensi 2), terjadi fenomena penyempitan informasi (*information bottleneck*) yang parah. Akibatnya, informasi penting mengenai bentuk pakaian terbuang, yang terrefleksi dari tingginya nilai *loss* (0.0247) serta hasil visualisasi yang tampak kabur. Namun, saat ruang laten diperluas hingga Dimensi 32, model mendapatkan ruang representasi yang memadai untuk menangkap variasi bentuk, lipatan, garis, dan jenis pakaian. Hal ini dibuktikan dengan penurunan drastis nilai *loss* hingga mencapai titik terendah (0.0085), yang secara langsung berbanding lurus dengan hasil citra rekonstruksi yang sangat tajam, bersih, dan mendekati akurasi visual dari citra Fashion-MNIST asli.

5. Analisis Mekanisme Inferensi Terminal dan Refleksi Kritis Kapasitas Generatif Decoder

Proses pengujian inferensi yang dipindahkan dari ekosistem notebook ke lingkungan baris perintah (terminal/command prompt) memberikan pemahaman teknis yang mendalam mengenai portabilitas

sebuah model kecerdasan buatan. Terdapat perbedaan mendasar di mana eksekusi lewat terminal menuntut kemandirian skrip program dalam mengelola memori dan berkas. Skrip terminal diwajibkan untuk mendeklarasikan ulang struktur arsitektur kelas *Encoder*, *Decoder*, atau *Autoencoder* secara presisi dan identik dengan apa yang telah dilatih sebelumnya. Ketidaksesuaian sekecil apa pun pada susunan lapisan linier akan menyebabkan kegagalan sistem (*runtime error*) akibat ketidakcocokan dimensi matriks bobot saat memuat ulang dokumen parameter model (.pth) menggunakan fungsi `torch.load()`.

Lebih lanjut, pengujian generatif secara terisolasi pada komponen *decoder* dengan memberikan umpan berupa vektor laten acak (*random latent vector*) via terminal menunjukkan aspek yang sangat menarik. Meskipun input yang dimasukkan adalah deretan angka acak buatan, *decoder* tetap mampu mengonversinya menjadi struktur geometri pakaian yang logis dan memiliki karakteristik spasial bermakna. Fenomena eksperimental ini memicu refleksi kritis bahwa jaringan *autoencoder* tidak sekadar bertindak sebagai mesin penyalin (*copy-paste*) piksel mentah dari data latih. Sebaliknya, melalui proses minimalisasi *loss* yang panjang, model terbukti telah berhasil memahami, mempelajari, dan memetakan distribusi probabilitas kontinu serta pola semantik dari struktur bentuk benda-benda Fashion-MNIST ke dalam ruang laten berdimensi rendah tersebut.

6. Analisis Inferensi Melalui Terminal dan Pengujian Decoder

Proses pengujian model yang dijalankan melalui *command prompt* atau terminal memberikan perspektif penting mengenai portabilitas dan penerapan praktis model kecerdasan buatan di luar lingkungan notebook. Proses inferensi ini mengharuskan program untuk memuat arsitektur jaringan yang identik secara presisi dengan arsitektur saat pelatihan, serta memanggil kembali file bobot (.pth) yang telah disimpan. Ketidaksesuaian sekecil apa pun pada struktur layer akan menyebabkan kegagalan *runtime* karena ketidakcocokan parameter matriks.

Ketika dilakukan pengujian pada komponen *decoder* saja dengan memasukkan nilai vektor laten acak dari terminal, citra yang dihasilkan tetap menampilkan karakteristik struktural dari sebuah pakaian. Hal ini memberikan refleksi kritis bahwa *autoencoder* tidak sekadar mempelajari cara menyalin piksel demi piksel dari data input secara mentah (*copy-paste*). Sebaliknya, model ini benar-benar berhasil mempelajari pemetaan distribusi kontinu dan konsep geometri abstrak dari struktur pakaian di dalam *latent space*, sehingga ia mampu menggenerasikan visualisasi pakaian baru yang masuk akal secara struktural dari koordinat acak mana pun.

7. Kesimpulan

Berdasarkan seluruh rangkaian eksperimen yang telah dilakukan, dapat disimpulkan bahwa *autoencoder* bekerja secara efektif dalam mereduksi dimensi sekaligus membangun kembali citra Fashion-MNIST. Ukuran *latent dimension* memegang peranan vital di mana dimensi yang lebih besar (dimensi 32) menghasilkan nilai *loss* paling rendah dan kualitas rekonstruksi visual yang paling akurat. Melalui eksekusi program via terminal, terbukti pula bahwa arsitektur yang konsisten adalah kunci keberhasilan inferensi, dan komponen *decoder* memiliki kemampuan generatif yang mandiri dalam memahami karakteristik data, bukan sekadar menyalin input.

